Clustering Analysis pada Dataset Travel Reviews Menggunakan Metode K-Means, K-Medians, DBSCAN, Mean Shift, dan Fuzzy C-Means dengan Evaluasi Silhouette Coefficient

Andika Febrianto[1], Muhammad Khoirul Ilham[2]

[1,2,]*Sains Data, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya*

[1]24031554018@mhs.unesa.ac.id

[2]24031554193@mhs.unesa.ac.id

Kelas 2024A

Dosen Pengampu: Dinda Galuh Guminta, S.Stat., M.Stat.

Abstract: *This clustering analysis aims to cluster users travel preferences based on the Travel Reviews dataset from the UCI Machine Learning Repository using several clustering methods, namely K-Means, K-Medians, DBSCAN, Mean Shift, and Fuzzy C-Means. The data was processed through preprocessing and normalization stages to ensure scale consistency. The optimal number of clusters was determined using the Elbow and Silhouette Coefficient methods, with the best results obtained with two clusters. Evaluation using the Silhouette Coefficient indicates that K-Means performs best compared to the other methods. Subsequently, Exploratory Data Analysis (EDA) was conducted to identify the characteristics of each cluster. The analysis results reveal patterns of user clustering based on travel category preferences. This study underscores the importance of selecting the appropriate clustering method and conducting quantitative evaluation to achieve optimal clustering.*

Keywords: *Clustering, K-Means, Silhouette Coefficient, Travel Reviews, Exploratory Data Analysis (EDA)*

Abstrak: Analisis Clustering ini bertujuan untuk mengelompokkan preferensi wisata pengguna berdasarkan dataset Travel Reviews dari UCI Machine Learning Repository menggunakan beberapa metode clustering, yaitu K-Means, K-Medians, DBSCAN, Mean Shift, dan Fuzzy C-Means. Data diproses melalui tahap preprocessing dan normalisasi untuk memastikan keseragaman skala. Penentuan jumlah cluster optimal dilakukan menggunakan metode Elbow dan Silhouette, dengan hasil terbaik sebanyak dua cluster. Evaluasi menggunakan Silhouette Coefficient menunjukkan bahwa K-Means memiliki performa terbaik dibandingkan metode lainnya. Selanjutnya, dilakukan Exploratory Data Analysis (EDA) untuk mengidentifikasi karakteristik setiap cluster. Hasil analisis menunjukkan adanya pola pengelompokan pengguna berdasarkan preferensi kategori wisata. Penelitian ini menegaskan pentingnya pemilihan metode clustering dan evaluasi kuantitatif dalam menghasilkan pengelompokan yang optimal.

Kata Kunci: Clustering, K-Means, Silhouette Coefficient, Travel Reviews, Exploratory Data Analysis (EDA)

BAB I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital saat ini telah menghasilkan banyak data dalam jumlah besar, termasuk data yang berkaitan dengan preferensi pengguna terhadap berbagai kategori wisata. Data tersebut memiliki potensi besar untuk dianalisis guna memahami pola perilaku pengguna dalam memilih destinasi wisata.

Namun, data dengan banyak variabel seringkali memiliki kompleksitas yang tinggi dan sulit untuk dianalisis secara langsung. Selain itu, perbedaan skala antar variabel dapat menyebabkan bias dalam proses analisis, terutama pada metode berbasis jarak. Oleh karena itu, diperlukan metode yang mampu menyederhanakan struktur data sekaligus mengelompokkan objek berdasarkan kemiripan karakteristiknya.

Clustering merupakan salah satu teknik dalam yang digunakan untuk mengelompokkan data tanpa label (*unsupervised learning*). Metode ini memungkinkan data dikelompokkan berdasarkan kemiripan tertentu sehingga membentuk kelompok yang homogen di dalam cluster dan heterogen antar cluster [1].

Beberapa metode clustering yang akan digunakan antara lain K-Means, K-Medians, DBSCAN, Mean Shift, dan Fuzzy C-Means. Setiap metode memiliki pendekatan yang berbeda dalam membentuk cluster, sehingga menghasilkan performa yang berbeda [6]. Oleh karena itu, diperlukan analisis komparatif untuk menentukan metode terbaik yang sesuai dengan karakteristik data.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam analisis ini adalah:

1. Bagaimana karakteristik dataset Travel Reviews?
2. Bagaimana hasil clustering menggunakan berbagai metode?
3. Metode clustering mana yang memberikan hasil terbaik?
4. Bagaimana karakteristik masing-masing cluster yang terbentuk?

1.3 Tujuan

1. Mendeskripsikan karakteristik data Travel Reviews
2. Menerapkan berbagai metode clustering
3. Membandingkan performa metode clustering
4. Mengidentifikasi pola segmentasi pengguna

BAB II. METODE ANALISIS

2.1 Deskripsi Dataset

Data pada analisis ini memberikan gambaran mengenai preferensi wisata pengguna berdasarkan penilaian terhadap berbagai kategori tempat wisata. Dataset yang digunakan terdiri dari 980 observasi, di mana setiap observasi merepresentasikan satu pengguna dengan karakteristik preferensi yang berbeda. Variabel yang digunakan dalam analisis ini terdiri dari sepuluh variabel numerik, yaitu Category.1 hingga Category.10, yang merepresentasikan tingkat penilaian pengguna terhadap kategori wisata tertentu. Seluruh variabel digunakan sebagai fitur dalam proses clustering. Dataset diperoleh dari UCI Machine Learning Repository dan telah melalui tahap preprocessing berupa penghapusan fitur yang tidak relevan serta standardisasi data untuk memastikan keseragaman skala antar variabel sebelum dilakukan proses clustering. Data tersebut kemudian digunakan untuk menganalisis pola segmentasi pengguna berdasarkan preferensi wisata, seperti yang ditunjukkan pada Tabel 1 yang berisi daftar variabel yang digunakan dalam analisis.

Tabel 1. Variable Analysis

Simbol	Nama Variable
X1	Category 1
X2	Category 2
X3	Category 3
X4	Category 4
X5	Category 5
X6	Category 6
X7	Category 7
X8	Category 8
X9	Category 9
X10	Category 10

2.2. Penentuan Jumlah Cluster (k)

Elbow Method merupakan metode yang digunakan untuk menentukan jumlah cluster dengan menganalisis hubungan antara jumlah cluster (k) dan nilai *Within Cluster Sum of Squares* (WCSS), yaitu ukuran variasi data dalam satu cluster. Semakin kecil nilai WCSS, maka cluster yang terbentuk semakin sempurna. Namun, penambahan jumlah cluster tidak selalu memberikan penurunan WCSS yang signifikan. Oleh karena itu, jumlah cluster optimal ditentukan pada titik "siku" (elbow), yaitu ketika penurunan WCSS mulai melambat [7].

Selain itu, digunakan *Silhouette Coefficient* untuk mengukur kualitas pemisahan cluster dengan membandingkan jarak antar data dalam cluster yang sama dan cluster lainnya. Nilai silhouette berkisar antara -1 hingga 1, di mana nilai yang lebih tinggi menunjukkan bahwa data berada pada cluster yang tepat [8]. Berdasarkan kedua metode tersebut, diperoleh jumlah cluster optimal yaitu $k = 2$, yang digunakan pada metode clustering berbasis partisi.

2.3 K-Means Clustering

K-Means merupakan metode clustering berbasis partisi yang bertujuan untuk mengelompokkan data dengan meminimalkan jarak antara data dan pusat cluster (centroid) yang dihitung menggunakan rata-rata [2], [6]. Proses K-Means dilakukan secara iteratif melalui penentuan centroid awal, pengelompokan data berdasarkan jarak terdekat, serta pembaruan centroid hingga mencapai kondisi konvergen. Metode ini memiliki keunggulan dalam efisiensi komputasi, namun sensitif terhadap outlier dan inisialisasi awal centroid [2].

2.4 K-Medians Clustering

K-Medians merupakan variasi dari K-Means yang menggunakan median sebagai pusat cluster. Pendekatan ini membuat metode lebih robust terhadap outlier dibandingkan K-Means [3]. Pengelompokan dilakukan menggunakan jarak Manhattan dengan proses iteratif hingga pusat cluster stabil. Metode ini digunakan sebagai pembanding untuk melihat pengaruh penggunaan median dalam proses clustering [3].

2.5 DBSCAN

DBSCAN merupakan metode clustering berbasis densitas yang mengelompokkan data berdasarkan kepadatan lokal serta mampu mendeteksi noise secara otomatis [4]. Metode ini menggunakan parameter epsilon (ε) dan minimum points (MinPts) untuk menentukan cluster. Data diklasifikasikan menjadi core point, border point, dan noise [4], [8]. DBSCAN efektif untuk mendeteksi bentuk cluster yang tidak beraturan, namun sensitif terhadap pemilihan parameter [6].

2.6 Mean Shift Clustering

Mean Shift merupakan metode clustering non-parametrik yang tidak memerlukan jumlah cluster di awal. Metode ini bekerja dengan menggeser titik data menuju pusat densitas (*mode*) berdasarkan fungsi kernel [6]. Metode ini mampu mendeteksi cluster dengan bentuk fleksibel, namun memiliki kompleksitas komputasi yang relatif tinggi [7].

2.7 Fuzzy C-Means Clustering

Fuzzy C-Means merupakan metode *soft clustering* yang memungkinkan setiap data memiliki derajat keanggotaan pada lebih dari satu cluster [7]. Pengelompokan dilakukan dengan meminimalkan fungsi objektif berbasis bobot keanggotaan. Metode ini cocok untuk data dengan batas cluster yang tidak tegas, namun memiliki kompleksitas perhitungan yang lebih tinggi dibandingkan metode hard clustering [6].

2.8 Evaluasi Clustering (*Silhouette Coefficient*)

Evaluasi hasil clustering dilakukan menggunakan *Silhouette Coefficient* untuk mengukur kualitas pemisahan antar cluster [8]. Nilai silhouette berkisar antara -1 hingga 1. Nilai yang mendekati 1 menunjukkan bahwa data berada pada cluster yang tepat, sedangkan nilai negatif menunjukkan kemungkinan kesalahan pengelompokan. Dalam analisis ini, nilai silhouette digunakan untuk membandingkan performa metode K-Means, K-Medians, DBSCAN, Mean Shift, dan Fuzzy C-Means, sehingga dapat ditentukan metode clustering terbaik [9], [10].

BAB III. HASIL DAN PEMBAHASAN

3.1 Karakteristik Dataset

Tabel 2. Statistika Deskriptif

Variable	Min	Q1	Med	Mean	Q3	Max
Cate 1	-1.69	-0.68	-0.19	0.00	0.38	7.11
Cate 2	-2.82	-0.57	-0.15	0.00	0.43	4.78
Cate 3	-1.12	-0.94	-0.24	0.00	0.70	3.30
Cate 4	-1.36	-0.43	-0.11	0.00	0.16	10.39
Cate 5	-2.01	-0.68	-0.09	0.00	0.59	5.39
Cate 6	-3.15	-0.70	-0.07	0.00	0.66	3.53
Cate 7	-2.67	-0.12	-0.12	0.00	-0.12	3.71
Cate 8	-3.01	-0.69	-0.10	0.00	0.54	4.03
Cate 9	-2.27	-0.71	-0.08	0.00	0.52	4.38
Cate10	-2.05	-0.80	-0.05	0.00	0.74	2.67

Berdasarkan hasil statistika deskriptif pada Tabel 2 terhadap data analisis, diperoleh gambaran umum mengenai karakteristik masing-masing variabel pada dataset preferensi wisata. Secara keseluruhan, seluruh variabel memiliki nilai rata-rata (mean) sebesar 0, yang menunjukkan bahwa proses standardisasi berhasil menghilangkan perbedaan skala antar variabel sehingga data berada pada distribusi yang terpusat.

Nilai median pada seluruh variabel cenderung berada di sekitar nol, yang menunjukkan bahwa distribusi data relatif simetris setelah dilakukan transformasi. Namun, terdapat perbedaan rentang nilai antar variabel yang cukup signifikan. Beberapa variabel seperti Category.4 dan Category.1 memiliki nilai maksimum yang cukup tinggi, masing-masing sebesar 10.39 dan 7.11, yang berarti terdapat outlier dalam data. Selain itu, nilai minimum pada beberapa variabel seperti Category.6 (-3.15) dan Category.8 (-3.01) menunjukkan bahwa terdapat variasi data yang cukup lebar pada sisi negatif. Perbedaan antara kuartil pertama (Q1) dan kuartil ketiga (Q3) pada setiap variabel juga menunjukkan tingkat penyebaran data yang beragam, di mana variabel seperti Category.3 dan Category.6 memiliki variasi yang lebih besar dibandingkan variabel lainnya.

3.2 Pre-Processing

Pre-processing dilakukan dengan menghapus kolom User.ID karena tidak relevan dalam clustering. Setelah itu, dilakukan eksplorasi awal untuk melihat karakteristik data. Data kemudian distandardisasi menggunakan metode z-score agar seluruh variabel memiliki skala yang sama (mean = 0 dan standar deviasi = 1), sehingga tidak terjadi dominasi variabel dalam perhitungan jarak [5]. Hasil scaling divalidasi melalui statistika deskriptif yang menunjukkan bahwa seluruh variabel telah memiliki rata-rata mendekati nol

3.3 Penenjuan Jumlah Cluster (k)

Penentuan jumlah cluster dilakukan untuk memperoleh jumlah kelompok yang paling optimal sebelum proses clustering dilakukan. Pada analisis ini, digunakan dua pendekatan, yaitu *Elbow Method* dan *Silhouette Coefficient*, untuk memastikan hasil yang lebih akurat dan tidak bias terhadap satu metode saja.

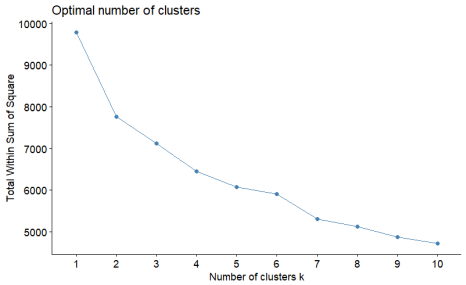

Gambar 1. Elbow Method

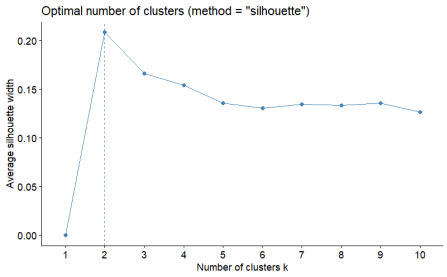

Gambar 2. Silhouette Method

Pada gambar 1, hasil menunjukkan kurva yang menurun dari kiri ke kanan. Titik di mana penurunan kurva mulai melandai secara tajam yang disebut "siku" (elbow), dan pada titik tersebut nilai k yang optimal. Pada gambar 2, hasil menunjukkan nilai rata-rata silhouette untuk setiap nilai k, dan k dengan nilai silhouette tertinggi adalah yang terbaik. Dari kedua gambar di atas, terlihat bahwa k=2 merupakan jumlah cluster yang digunakan.

3.4 K-Means

Tabel 3. Score K-Means

Skor
0.2131536

Pada tabel 3, diketahui nilai silhouette sebesar 0,213 menunjukkan kualitas cluster rendah, sehingga pemisahan antar cluster belum optimal dan masih terjadi overlap.

Tabel 4. Cluster K-Means

Cluster	Jumlah
1	374
2	606

Tabel 4 menunjukkan distribusi jumlah anggota cluster, yaitu sebanyak 374 data berada pada cluster 1 dan 606 data berada pada cluster 2. Hal ini menunjukkan bahwa pembagian cluster tidak seimbang, di mana cluster 2 memiliki jumlah anggota yang lebih besar dibandingkan cluster 1, yang menunjukkan bahwa sebagian besar data memiliki karakteristik yang lebih mendekati pola pada cluster 2.

3.5 K-Medians

Tabel 5. Skor K-Medians

Skor
0.2079888

Tabel 5 menunjukkan nilai silhouette sebesar 0,207 menunjukkan kualitas cluster rendah, sehingga pemisahan antar cluster kurang jelas dan masih terjadi overlap.

Tabel 6. Cluster K-Medians

Cluster	Jumlah
1	300
2	680

Tabel menunjukkan bahwa cluster 1 berisi 300 data, sedangkan cluster 2 berisi 680 data. Distribusi ini menunjukkan bahwa cluster 2 memiliki jumlah anggota yang jauh lebih besar dibandingkan cluster 1, sehingga pembagian cluster tidak seimbang. Ketidakseimbangan ini menunjukkan bahwa sebagian besar data memiliki karakteristik yang lebih mirip satu sama lain dan membentuk kelompok besar pada cluster 2, sedangkan cluster 1 hanya mewakili sebagian kecil data dengan pola yang berbeda.

3.6 DBSCAN

Tabel 7. Skor DBSCAN

Skor
0.1828381

Tabel 7 menunjukkan nilai silhouette sekitar 0,18 menunjukkan kualitas cluster rendah, dengan pemisahan yang kurang jelas dan distribusi cluster tidak seimbang, sehingga DBSCAN kurang optimal dibanding metode sebelumnya.

Tabel 8. Cluster DBSCAN

Cluster	Jumlah
0	90
1	878
2	6
3	6

Tabel 8 menunjukkan bahwa terdapat 90 data yang dikategorikan sebagai noise (cluster 0), 878 data dalam cluster utama (cluster 1), serta masing-masing 6 data dalam cluster 2 dan cluster 3. Distribusi ini menunjukkan bahwa sebagian besar data sangat terkonsentrasi dalam satu cluster besar, sedangkan cluster lain sangat kecil dan cenderung tidak signifikan. Keberadaan 90 noise juga menunjukkan bahwa DBSCAN berhasil mengidentifikasi sejumlah data yang tidak mengikuti pola umum, yang merupakan keunggulan utama metode ini.

3.7 Mean Shift

Tabel 9. Skor Mean Shift

Skor
-0.1080996

Tabel 9 menunjukkan nilai silhouette -0,108 menunjukkan kualitas cluster sangat buruk, dengan banyak overlap dan struktur cluster yang tidak jelas.

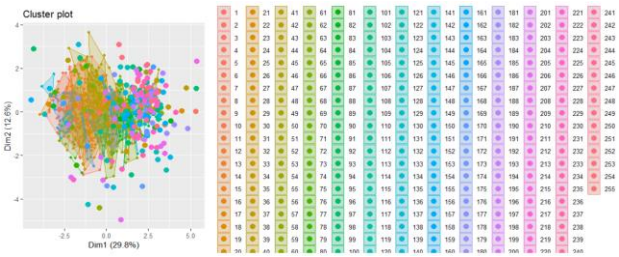

Gambar 3. Cluster Mean Shift

Dari gambar 3, diketahui Mean Shift menghasilkan terlalu banyak cluster (hingga 255) akibat bandwidth yang terlalu kecil, sehingga cluster menjadi sangat terfragmentasi dan tidak membentuk pola yang jelas.

3.8 Fuzzy C-Means

Tabel 10. Derajat Keanggotaan

Data	Cluster 1	Cluster 2
1	0.2966420	0.7033580
2	0.3877458	0.6122542
3	0.5774000	0.4226000
4	0.6410730	0.3589270
5	0.3817986	0.6182014
6	0.6713357	0.3286643

Tabel 10 menunjukkan bahwa setiap data memiliki dua nilai keanggotaan, yaitu terhadap Cluster 1 dan Cluster 2. Seperti pada data pertama memiliki nilai 0.2966420 untuk Cluster 1 dan 0.7033580 untuk Cluster 2, yang berarti data tersebut lebih cenderung masuk ke Cluster 2, namun masih memiliki keterkaitan dengan Cluster 1. Hal ini menunjukkan bahwa batas antar cluster tidak tegas.

Tabel 11. Skor Fuzzy C-Means

Skor
0.200511

Tabel 11 dengan nilai silhouette 0,201 menunjukkan kualitas cluster masih lemah, dengan pemisahan yang belum jelas dan adanya overlap antar cluster.

Tabel 12. Cluster Fuzzy C-Means

Cluster	Jumlah
1	547
2	433

Tabel 12 menunjukkan bahwa seluruh data hanya terbagi ke dalam dua cluster, yaitu cluster 1 dan cluster 2. Menunjukkan jumlah anggota pada masing-masing cluster, yaitu sebanyak 547 data pada cluster 1 dan 433 data pada cluster 2. Distribusi ini cukup seimbang meskipun cluster 1 memiliki jumlah anggota yang sedikit lebih banyak dibandingkan cluster 2.

3.9 Perbandingan Metode

Tabel 13. Perbandingan Metode Clustering

Rank	Metode	Silhouette
1	K-Means	0.2131536
2	K-Medians	0.2079888
3	Fuzzy C-Means	0.2005110
4	DBSCAN	0.1828381
5	Mean Shift	-0.1080996

Pada tabel 13 menunjukkan urutan metode clustering berdasarkan performanya, yaitu K-Means berada di peringkat pertama dengan nilai Silhouette sebesar 0.2131536, diikuti oleh K-Medians dengan nilai 0.2079888, kemudian Fuzzy C-Means dengan nilai 0.2005110, DBSCAN dengan nilai 0.1828381, dan terakhir Mean Shift dengan nilai negatif sebesar -0.1080996. Nilai negatif pada Mean Shift mengartikan bahwa banyak data kemungkinan berada pada cluster yang kurang tepat atau terjadi overlap yang cukup tinggi antar cluster, sehingga kualitas clustering-nya paling rendah dibandingkan metode lainnya. Perbedaan nilai antar metode sebenarnya tidak terlalu jauh untuk tiga metode teratas (K-Means, K-Medians, dan Fuzzy C-Means), yang menunjukkan bahwa ketiganya memiliki performa yang relatif mirip dalam mengelompokkan data. Namun, K-Means tetap unggul karena menghasilkan nilai Silhouette tertinggi, yang berarti pemisahan antar cluster lebih optimal dibandingkan metode lainnya.

3.10 Metode Terbaik

Dari hasil clustering dengan kelima metode, diperoleh bahwa metode terbaik adalah K-Means dengan nilai Silhouette sebesar 0.2131536. Hal ini menandakan bahwa K-Means merupakan metode yang paling sesuai untuk dataset yang digunakan dalam analisis ini, karena mampu menghasilkan cluster dengan tingkat pemisahan dan konsistensi yang paling baik dibandingkan metode lain yang diuji.

Tabel 14. Cluster Final

Cluster	Jumlah
1	374
2	606

Tabel 14 menunjukkan bahwa terdapat dua cluster utama, yaitu cluster 1 dengan jumlah 374 data dan cluster 2 dengan jumlah 606 data. Distribusi ini menunjukkan bahwa cluster 2 memiliki jumlah anggota yang lebih banyak dibandingkan cluster 1, sehingga dapat dikatakan bahwa sebagian besar data cenderung memiliki karakteristik yang mirip dengan cluster 2.

3.11 EDA pada Metode Terbaik

Tabel 15. Proporsi Cluster yang Terbentuk

Cluster	Proporsi
1	0.3816327
2	0.6183673

Tabel 15 menunjukkan proporsi masing-masing cluster yang terbentuk, yaitu sekitar 38.16% untuk cluster 1 dan 61.84% untuk cluster 2. Distribusi ini menunjukkan bahwa mayoritas data berada pada cluster 2, sehingga cluster tersebut dapat dianggap sebagai kelompok dominan dalam dataset.

Tabel 16. Fitur Dominan Tiap Cluster

Cluster	Name	Value
1	Category 7	3.19
1	Category 8	2.80
1	Category 10	2.54
2	Category 7	3.18
2	Category 10	2.96
2	Category 8	2.85

Pada tabel 16, diketahui fitur yang paling dominan adalah Category.7, Category.8, dan Category.10, yang memiliki nilai rata-rata tertinggi dibandingkan fitur lainnya. Hal ini menunjukkan bahwa cluster 1 cenderung memiliki intensitas tinggi pada kategori-kategori yang ada. Pada cluster 2, fitur dominan juga mencakup Category.7, Category.10, dan Category.8, namun dengan kombinasi nilai yang sedikit berbeda, terutama pada Category.10 yang memiliki nilai lebih tinggi dibandingkan cluster 1.

BAB IV. KESIMPULAN DAN SARAN

Berdasarkan hasil analisis clustering pada dataset *Travel Reviews*, dapat disimpulkan bahwa seluruh metode yang digunakan (K-Means, K-Medians, DBSCAN, Mean Shift, dan Fuzzy C-Means) mampu membentuk cluster, namun kualitas pemisahan yang dihasilkan secara umum masih tergolong rendah. Hal ini ditunjukkan oleh nilai *Silhouette Coefficient* yang

berada di kisaran 0.18-0.21, bahkan bernilai negatif pada Mean Shift, yang mengindikasikan adanya overlap antar cluster dan struktur kelompok yang belum jelas. Metode K-Means memberikan performa terbaik dengan nilai silhouette sebesar 0.213, diikuti oleh K-Medians dan Fuzzy C-Means dengan nilai yang relatif mendekati. Sedangkan, DBSCAN menghasilkan satu cluster dominan dengan beberapa cluster kecil serta noise, dan Mean Shift menghasilkan terlalu banyak cluster akibat pemilihan parameter bandwidth yang kurang tepat. Oleh karena itu, K-Means dipilih sebagai metode terbaik dalam penelitian ini. Hasil clustering terbaik menunjukkan bahwa data terbagi menjadi dua cluster dengan proporsi 38.16% dan 61.84%. Kedua cluster memiliki karakteristik yang relatif mirip, dengan fitur dominan pada Category.7, Category.8, dan Category.10, yang menunjukkan bahwa preferensi pengguna cenderung terfokus pada kategori wisata tertentu.

Untuk pengembangan analisis selanjutnya, disarankan untuk melakukan tuning parameter secara lebih mendalam, terutama pada metode DBSCAN dan Mean Shift, agar diperoleh hasil clustering yang lebih optimal. Selain itu, penggunaan metode evaluasi tambahan seperti Davies-Bouldin Index atau Calinski-Harabasz Index dapat memberikan perspektif yang lebih komprehensif dalam menilai kualitas cluster. Disarankan juga untuk melakukan eksplorasi metode clustering lain atau pendekatan berbasis dimensionality reduction seperti PCA sebelum clustering, guna mengurangi kompleksitas data dan meningkatkan kualitas pemisahan cluster. Selain itu, analisis lanjutan terhadap interpretasi cluster secara lebih mendalam juga diperlukan agar hasil segmentasi dapat memberikan insight yang lebih aplikatif dalam pengambilan keputusan di bidang pariwisata.

DAFTAR PUSTAKA

[1] M. Alsmadi et al., “A Survey on Clustering Algorithms and Their Constraints,” 2023.

[2] D. Arthur and S. Vassilvitskii, “An Extensive Empirical Comparison of K-Means Initialization Algorithms,” University of Essex Repository, 2022.

[3] S. S. Basha et al., “Efficiency Evaluation of K-Means, K-Medians and K-Mode Clustering Methods Using SSD,” 2024.

[4] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise (DBSCAN Revisited),” Northeastern University Lecture Notes, 2021.

[5] D. R. Sari et al., “Penerapan Algoritma Clustering dalam Data Mining,” Seminar Nasional Teknologi Informasi dan Komputer, 2022.

[6] J. Zhang et al., “Advances in Clustering Algorithms for Data Analysis,” Expert Systems with Applications, 2023.

[7] A. Saxena, M. Prasad, A. Gupta, N. Bharill, O. P. Patel, A. Tiwari, M. J. Er, W. Ding, and C.-T. Lin, “A Review of Clustering Techniques and Developments,” Neurocomputing, vol. 267, pp. 664-681, 2017.

[8] A. Fahad et al., “A Survey of Clustering Algorithms for Big Data: Taxonomy and Empirical Analysis,” Ain Shams Engineering Journal, vol. 10, no. 1, pp. 121–135, 2019.

[9] H. Wang et al., “Clustering Optimization Using Machine Learning Techniques,” IEEE, 2024.

[10] R. Kurniawan, A. Nugroho, and D. Setiawan, “Implementasi Algoritma Clustering pada Data Mining,” Jurnal Komputa, vol. 13, no. 1, 2024. doi: 10.34010/komputa.v13i1.11710

LAMPIRAN

Link Dataset: https://archive.ics.uci.edu/dataset/484/travel+reviews
Link R-Pubs: https://rpubs.com/andkfbrnt018/1421241
Link Github: https://github.com/AndikaFebrianto018/CLUSTERING-ANALYSIS

Sample Dataset

User ID	Category 1	Category 2	···	Category 9	Category 10
User 1	0.93	1.80		1.82	2.42
User 2	1.02	2.20		1.86	2.32
			⋮		
User 979	0.93	0.20		1.12	2.46
User 980	0.93	0.56		1.34	2.40

Visualisasi Clustering:

- **K-Means**

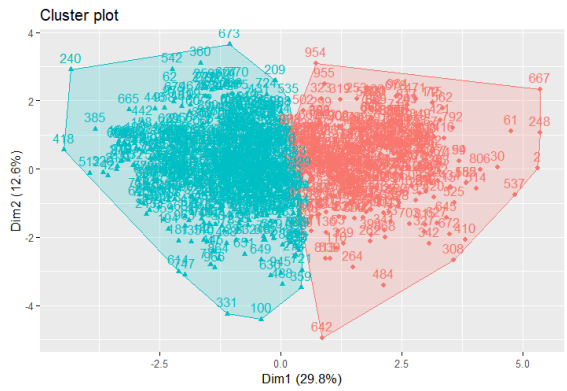

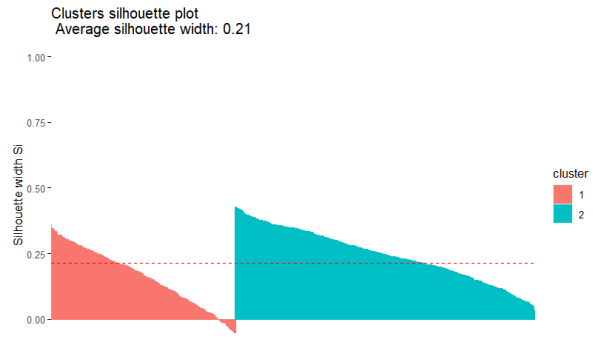

- **K-Medians**

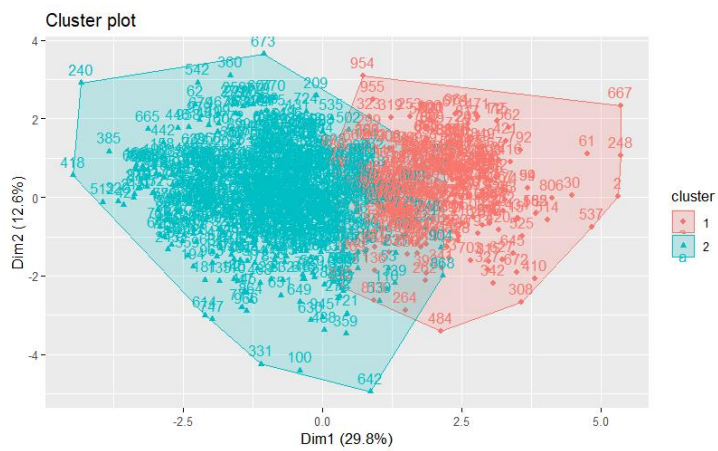

- **DBSCAN**

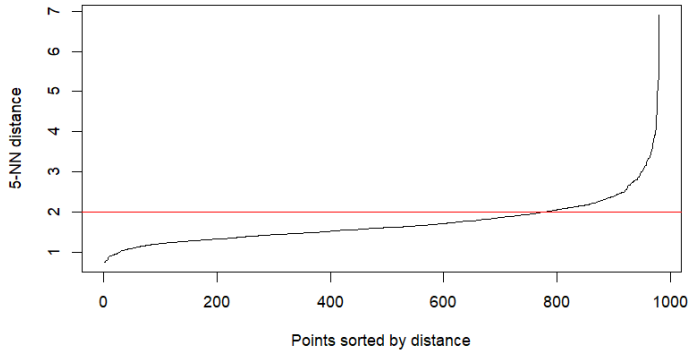

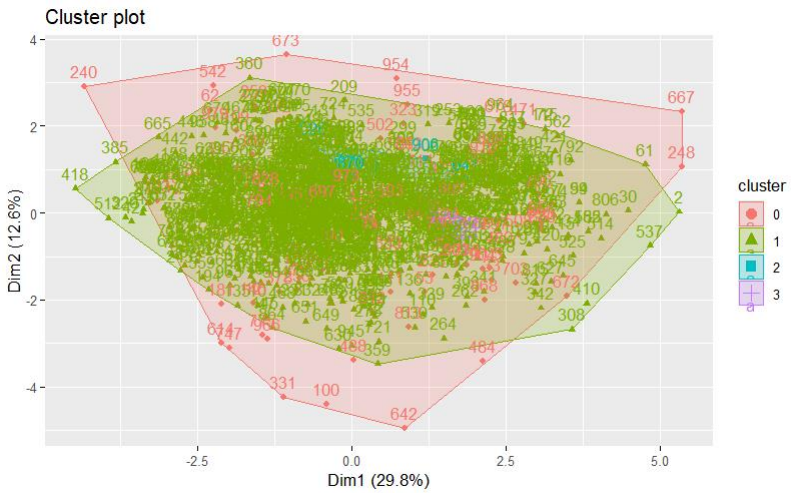

- **Fuzzy C-Means**

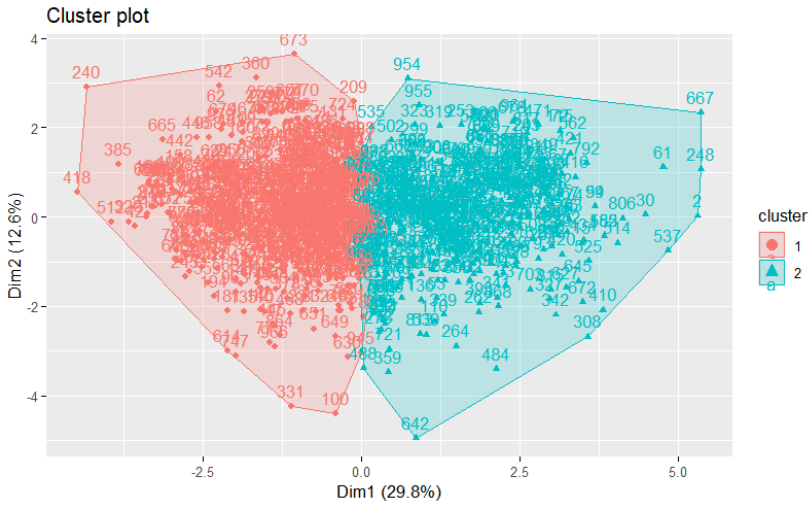

EDA pada Metode Terbaik

- **PCA Visualization**

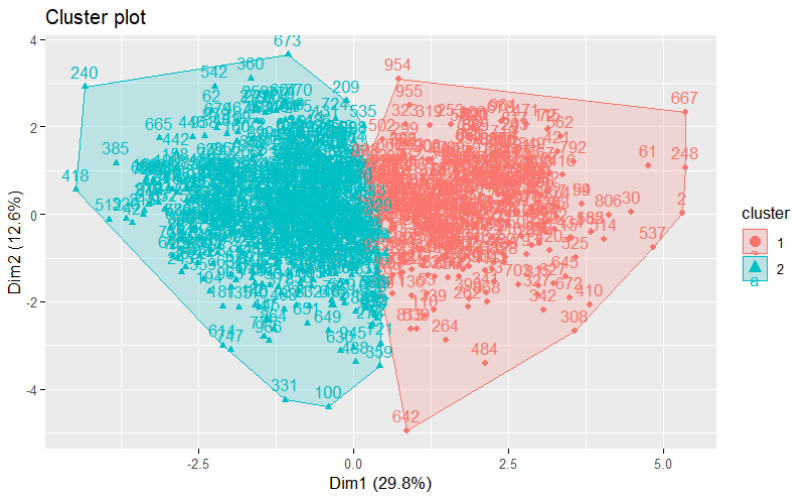
Cluster plot
Dim2 (12.6%)
Dim1 (29.8%)
cluster
1
2

- **BoxPlot**

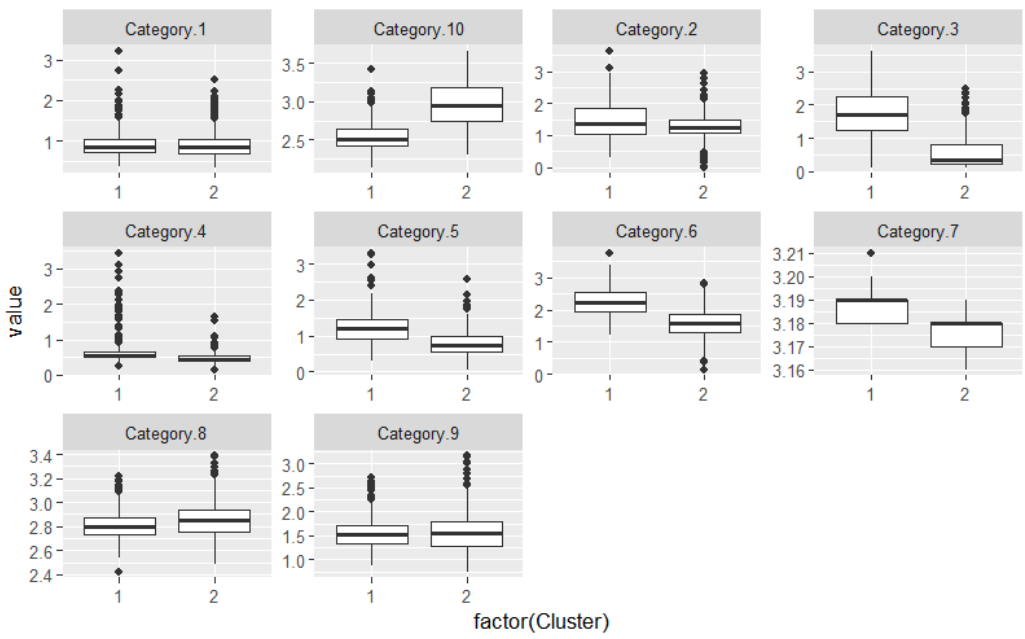
Category.1
Category.10
Category.2
Category.3
Category.4
Category.5
Category.6
Category.7
Category.8
Category.9
value
factor(Cluster)